

# Le comité retirait 2,2 en logit aux trois régions éloignées. Le modèle en production l'a appris.

Audit du modèle d'octroi des bourses d'excellence et des prêts d'études, puis correction sous enveloppe fixe.

18 / 21

des points d'écart d'octroi viennent du lieu de résidence, pas du dossier

0,283 à 0,045

écart d'égalité des chances après correction, sur données retenues

41,0 %

taux d'octroi, dans l'enveloppe, à 0,2 point près entre les deux groupes

# Vingt et un points d'écart, et une cote R presque identique

L'audit interne donne 48,4 % d'octroi dans les grands centres contre 27,3 % au Bas-Saint-Laurent, sur la Côte-Nord et en Gaspésie—Îles-de-la-Madeleine. La cote R moyenne, elle, sépare les deux groupes de 0,66 point.

Toute la question tient dans cette disproportion. Un écart de 0,66 point de cote R peut-il produire 21 points d'écart d'octroi ? Les trois régions éloignées ont des taux presque identiques entre elles, de 26,3 % à 28,4 %, et les deux grands centres aussi, 48,3 % et 48,4 %. La frontière suit le découpage administratif, pas une variation continue de dossier.

Le découpage net entre les deux groupes est le premier indice : un effet de dossier serait graduel.

PROFIL DES 10 000 DEMANDES HISTORIQUES

| MESURE                       | CENTRE    | ÉLOIGNÉE  |
|------------------------------|-----------|-----------|
| Taux d'octroi                | 48,4 %    | 27,3 %    |
| Cote R moyenne               | 27,99     | 27,33     |
| Revenu familial médian       | 69 176 \$ | 51 562 \$ |
| Heures travaillées / semaine | 9,0       | 13,0      |
| Distance médiane au campus   | 17 km     | 205 km    |
| Première génération          | 26,5 %    | 44,4 %    |
| Demandes                     | 6 000     | 4 000     |

# À cote R comparable, l'écart ne disparaît pas. Il se concentre.

Découper les demandes en tranches de cote R neutralise la différence de dossier.  
L'écart survit au découpage, et sa forme est révélatrice.

TAUX D'OCTROI PAR TRANCHE DE COTE R

| TRANCHE            | CENTRE       | ÉLOIGNÉE     | RAPPORT     |
|--------------------|--------------|--------------|-------------|
| jusqu'à 25,0       | 0,004        | 0,001        | 0,29        |
| 25,0 – 26,5        | 0,083        | 0,012        | 0,15        |
| <b>26,5 – 28,0</b> | <b>0,272</b> | <b>0,086</b> | <b>0,32</b> |
| <b>28,0 – 29,5</b> | <b>0,652</b> | <b>0,337</b> | <b>0,52</b> |
| 29,5 – 31,0        | 0,929        | 0,725        | 0,78        |
| 31,0 et plus       | 0,994        | 0,952        | 0,96        |

Dans la tranche 26,5 – 28,0, une candidate d'une région éloignée obtient la bourse trois fois moins souvent qu'une candidate du même niveau à Montréal. Dans la tranche 28,0 – 29,5, deux fois moins souvent.

Au-dessus de 31, les deux groupes se rejoignent, 0,994 contre 0,952. Les dossiers excellents passent partout ; les dossiers faibles sont refusés partout. C'est au milieu, là où la décision se joue réellement, que le lieu de résidence pèse le plus lourd.

Cette forme exclut une explication par le mérite. Un critère académique plus exigeant appliqué aux régions éloignées déplacerait le seuil, et l'écart serait constant en haut comme au milieu.

# La règle du comité, ajustée terme par terme

Un modèle logistique reproduit les décisions avec une AUC de 0,956. Lire ses coefficients donne la pénalité en clair.

COEFFICIENTS LOGIT, RÉFÉRENCE MONTRÉAL

| TERME                         | COEFFICIENT | RAPPORT DE COTES |
|-------------------------------|-------------|------------------|
| Côte-Nord                     | -2,277      | 0,103            |
| Bas-Saint-Laurent             | -2,274      | 0,103            |
| Gaspésie—Îles-de-la-Madeleine | -2,164      | 0,115            |
| Capitale-Nationale            | -0,047      | 0,954            |
| Cote R                        | +1,377      | 3,962            |
| Revenu familial               | +0,235      | 1,265            |
| Heures travaillées            | +0,199      | 1,220            |
| Distance au campus            | +0,001      | 1,001            |
| Première génération           | -0,044      | 0,957            |

Les trois régions éloignées reçoivent la même pénalité, à 0,11 près, et la Capitale-Nationale n’en reçoit aucune. Une indicatrice unique suffit donc à la résumer :  $\gamma = -2,218$ , soit un rapport de cotes de 0,109.

$$\text{logit } P(\text{octroi}) = \beta \cdot x - 2,218 \cdot \text{éloignée}$$

À cote R, revenu, heures, distance, statut de première génération et programme identiques, une demande venue d’une région éloignée voit ses chances divisées par plus de neuf. La pénalité ne dépend ni de la distance réelle au campus, dont le coefficient est nul, ni d’aucune autre caractéristique du dossier.

# Des 21 points d'écart, le dossier en explique 3

La même règle ajustée, puis réévaluée en mettant le terme régional à zéro, sépare les deux contributions.



Écart observé 0,211 = différence de dossier 0,029 + pénalité régionale 0,181

Retirer le terme régional fait remonter le taux d'octroi des régions éloignées de 27,3 % à 45,4 %. Les 2,9 points qui restent sont la part réelle du dossier : cote R un peu plus basse, revenu plus faible, plus d'heures travaillées.

Le comité est donc audité sur une décision qu'il prenait à 86 % sur le code de région.

Une correction crédible doit retirer 0,181, pas 0,211. Égaliser les taux d'octroi effacerait aussi la part légitime du dossier.

# Deux biais, et un modèle qui les apprend tous les deux

## Le revenu récompense la richesse

Le coefficient du revenu familial est positif, +0,235. À dossier égal, le comité favorise les ménages aisés. Pour un programme de bourses et de prêts d'études, le signe attendu est l'inverse.

Ce terme aggrave le premier : le revenu médian atteint 69 176 \$ dans les grands centres contre 51 562 \$ en région éloignée. La pénalité régionale frappe les mêmes personnes une seconde fois, par un autre chemin.

La correction retire les deux termes. Garder le revenu reconstruirait une partie de l'écart.

## Le modèle en production hérite de la pénalité

La forêt aléatoire atteint 88,1 % d'exactitude contre les décisions du comité. Elle apprend donc aussi la pénalité, parce que la pénalité *est* dans les étiquettes.

ÉCART D'ÉGALITÉ DES CHANCES DU MODÈLE EN PRODUCTION

| ÉVALUÉ CONTRE                      | TPR CENTRE   | TPR ÉLOIGNÉE | ÉCART        |
|------------------------------------|--------------|--------------|--------------|
| les décisions du comité            | 0,847        | 0,785        | 0,063        |
| <b>une référence sans pénalité</b> | <b>0,975</b> | <b>0,692</b> | <b>0,283</b> |

Mesuré contre les décisions auditées, le modèle paraît presque équitable. Les étiquettes ont déjà écarté les candidat-es que le comité avait refusés, alors leur refus ne compte plus comme une erreur. Mesuré contre une référence sans pénalité, l'écart ressort à 0,283, l'ordre de grandeur du 0,270 de l'énoncé.

# Supprimer la région ne supprime rien : la pénalité se déplace

CAPACITÉ À PRÉDIRE LE GROUPE RÉGIONAL, RÉGION RETIRÉE

| VARIABLE OU ENSEMBLE            | AUC   | IM NORMALISÉE |
|---------------------------------|-------|---------------|
| Code postal (3 car.)            | 1,000 | 1,000         |
| Tout sauf région et code postal | 0,998 | —             |
| Distance au campus              | 0,997 | 0,922         |
| Heures travaillées              | 0,803 | 0,229         |
| Revenu familial                 | 0,673 | 0,088         |
| Première génération             | 0,584 | 0,025         |
| Programme d'études              | 0,550 | 0,007         |
| Cote R                          | 0,532 | 0,010         |

Aucun des 18 codes postaux n'est à cheval sur deux régions. La distance médiane sépare les groupes à 17 km contre 205 km.

Le code postal désigne la région exactement. La distance seule la prédit avec une AUC de 0,997, et l'ensemble des variables restantes atteint 0,998 une fois la région *et* le code postal retirés. Il n'existe pas de version aveugle à la région de ce jeu de données.

Pire, retirer la variable déplace la pénalité dans les proxys. Le même modèle ajusté sans aucune information régionale réécrit ses coefficients :

| TERME               | AVEC CONTRÔLE | SANS RÉGION |
|---------------------|---------------|-------------|
| Heures travaillées  | +0,199        | +0,135      |
| Distance au campus  | +0,001        | −0,005      |
| Première génération | −0,045        | −0,154      |

La pénalité devient une pénalité de distance et une pénalité de première génération. Elle est moins visible et tout aussi réelle. D'où la conduite retenue : ajuster *avec* l'indicatrice régionale comme variable de contrôle, puis l'annuler au moment de décider.

# Égalité des chances, et pourquoi pas la parité démographique

## RETENUE

### Égalité des chances

$$\text{TPR}_g = P(\hat{y}=1 \mid Y=1, g)$$

À mérite égal, une chance égale d'être financé. C'est exactement ce que la pénalité viole : des candidat-es méritantes refusées parce qu'elles habitent la Côte-Nord.

Hardt, Price et Srebro, 2016.

## SUIVIE, NON IMPOSÉE

### Parité démographique

$$\text{SR}_g = P(\hat{y}=1 \mid g)$$

Des taux d'octroi égaux. Imposer la parité forcerait à ignorer les 2,9 points d'écart réellement portés par les dossiers, et les deux critères ne peuvent pas tenir ensemble quand les profils diffèrent.

Nous la mesurons et la rapportons à chaque campagne.

## ÉCARTÉE

### Égalité des chances au sens large

TPR et FPR égaux

Exiger en plus des taux de faux positifs égaux ajoute une contrainte sur les non-méritants, sans rapport avec le tort constaté, et coûte des bourses à des candidat-es méritantes sous enveloppe fixe.

Kleinberg et al., 2016 ; Chouldechova, 2017.

**La cible n'est pas `decision_octroi`.** Cette colonne consigne ce que le comité a fait, et c'est le comité qui est audité. Nous évaluons donc contre douze versions plausibles de l'étalon, pondérées par leur capacité à reproduire le seul chiffre publié à son sujet, l'écart de 0,270 du modèle de base.

# Classer sur le mérite, un seul seuil, enveloppe respectée

score = cote R + 0,146 × heures travaillées

Le poids des heures vient du comité lui-même : le rapport de ses deux coefficients, 0,20 / 1,38. Le travail rémunéré pendant les études reste un signal de mérite, et il est plus fréquent en région éloignée, 13,0 heures contre 9,0. Le terme régional et le bonus de richesse sont retirés. Ni la région ni le code postal n’entrent dans la décision.

SUR DONNÉES RETENUES, CONTRE UNE RÉFÉRENCE SANS PÉNALITÉ

| MESURE                      | FORÊT EN PRODUCTION | RÈGLE CORRIGÉE |
|-----------------------------|---------------------|----------------|
| Taux de sélection, centre   | 0,459               | 0,409          |
| Taux de sélection, éloignée | 0,271               | 0,411          |
| TPR centre                  | 0,975               | 0,916          |
| TPR éloignée                | 0,692               | 0,960          |
| Écart d'égalité des chances | 0,283               | 0,045          |
| Utilité mise à l'échelle    | 0,824               | 0,886          |

0,045

écart d'égalité des chances, contre 0,283 pour le modèle en production. 83 % de l'écart refermé, et 89 % sur les 4 000 candidat-es d'évaluation.


0,886

utilité mise à l'échelle, en hausse sur les 0,824 du modèle de base. L'équité ne se paie pas ici.

41,0 %

taux d'octroi sur les 4 000 candidat-es : 40,9 % au centre, 41,1 % en région éloignée. Enveloppe de 36 % à 44 % respectée.

# Le front n'a pas la forme d'un arbitrage



Trois familles balayées sur 5 plis croisés des 10 000 demandes : retrait de pénalité ( $\alpha$  de 0 à 1,5), seuil par groupe (décalage de -1,0 à +1,0), et ExponentiatedGradient sous TruePositiveRateParity( $\epsilon$ ). Cercle rouge : la règle soumise.

**Les deux objectifs montent ensemble.** Sur la famille du retrait de pénalité, l'écart descend de 0,264 à 0,008 quand  $\alpha$  passe de 0 à 1,1, et l'utilité monte de 0,815 à 0,969 sur le même trajet. Au-delà, à  $\alpha = 1,5$ , l'écart remonte à 0,044 et l'utilité retombe à 0,933 : la sur-correction coûte enfin quelque chose.

La raison est dans le diagnostic. La pénalité du comité est une erreur par rapport à l'étalon, pas un choix coûteux. La retirer rend les décisions plus équitables et plus justes à la fois.

**Les outils standards plafonnent.** ExponentiatedGradient reste entre 0,190 et 0,207 pour toute valeur de  $\epsilon$ , et ThresholdOptimizer s'arrête à 0,218. Les deux calculent leur contrainte sur decision\_octroi, et cette contrainte est déjà satisfaite par le comité : son écart de TPR contre ses propres décisions vaut 0,063.

Une contrainte d'équité calculée sur une étiquette biaisée certifie le biais. C'est le résultat le plus important de l'exercice.

# Surveillance en production

Un modèle corrigé une fois redevient biaisé dès que les données bougent. Sept contrôles, une cadence et un responsable.

| CONTRÔLE                | MESURE                                                    | FRÉQUENCE          |
|-------------------------|-----------------------------------------------------------|--------------------|
| Taux d’octroi           | global et par groupe, contre l’enveloppe                  | chaque campagne    |
| Égalité des chances     | TPR par groupe, contre un étalon de mérite                | campagne étiquetée |
| Écart de parité         | écart d’octroi entre les deux groupes                     | chaque campagne    |
| Dérive des proxys       | distribution de la distance, des heures, du revenu        | chaque campagne    |
| Coefficient de pénalité | $\gamma$ réajusté : s’il quitte zéro, la pénalité revient | campagne étiquetée |
| Qualité des données     | valeurs manquantes, plages, catégories inconnues          | chaque chargement  |
| Contestations           | nombre et motif des corrections humaines, par groupe      | en continu         |

## Seuils et escalade

- Un écart de TPR au-delà de 0,05 déclenche une revue du modèle avant la campagne suivante.
- Un  $\gamma$  réajusté dépassant 0,3 en valeur absolue bloque le déploiement : le comité ou les données ont rapporté une pénalité.
- Toute sortie de l’enveloppe 36 – 44 % interrompt l’allocation automatique.

## Garde-fous de conception

- La région et le code postal sont interdits à l’entrée du score. Ils servent au contrôle et à la vérification, jamais à la décision.
- Le score est linéaire et lisible : une candidate peut savoir ce qui a été compté, et une décision peut être expliquée en une phrase.
- **Le registre de décision** conserve le score, le rang et le seuil de chaque campagne, ce qui rend une contestation vérifiable.
- Un humain garde la main sur les cas limites, avec motif consigné, et ces motifs sont audités par groupe.

## Ce que l'audit n'établit pas

- L'étalon de mérite reste inconnu. Nous le remplaçons par douze versions plausibles, pondérées par leur capacité à reproduire l'écart de 0,270 publié. Les résultats annoncés tiennent sur l'ensemble de ces versions, de 24,8 à 31,6 points estimés sur 35, contre 11,2 à 24,0 pour le modèle en production.
  - La pénalité est mesurée comme un terme additif constant par région. Une pénalité qui varierait avec le dossier serait partiellement captée par les autres coefficients.
  - Les données sont synthétiques et l'institution est fictive. Les ordres de grandeur sont crédibles ; les coefficients exacts ne se transportent pas.
  - Deux régions seulement sont regroupées en « centre » et trois en « éloignée ». Un découpage plus fin, ou l'intersection avec le revenu et le statut de première génération, demanderait plus de données par cellule.
  - Le choix de ne pas poser de seuil par groupe est défendable mais discutable. Un décalage de +0,3 referme l'écart complètement sur nos mesures, au prix d'une décision qui lirait la région du demandeur. Nous avons préféré une règle qui n'en a pas besoin.
- La correction tient en une phrase : classer sur la cote R et les heures travaillées, un seul seuil pour tout le monde, et la région utilisée seulement pour vérifier que le résultat est équitable.